

IA - Invatare automata

Material dezvoltat pentru examen

Teorie completa + rezolvari detaliate pentru modelele 2022, 2023 si 2025

Document de recapitulare generat din cursurile si modelele incarcate

2026

Contents

Cum folosesti documentul	3
1 Tiparul examenului	3
2 Teorie dezvoltata pentru examen	3
2.1 Invatare automata: obiectiv si notatie	3
2.2 Tipuri de invatare	3
2.3 Train, validation, test	4
2.4 Erori: modelare, estimare, optimizare	4
2.5 Eroare empirica si eroare de generalizare	4
2.6 Bias, variance, underfitting, overfitting	4
2.7 No free lunch si fenomenul Hughes	4
2.8 Metrice de evaluare	4
2.9 Kendall Tau	5
2.10 Naive Bayes si Laplace smoothing	5
2.11 k-NN si distante	5
2.12 Standardizare si normalizare	6
2.13 Batch normalization	6
2.14 Clasificatori liniari, SVM si Softmax	6
2.15 SVM hard-margin, soft-margin si variabila ξ	7
2.16 Kernel trick	7
2.17 Operatii valide cu kerneluri	7
2.18 Scufundarea kernelului polinomial pentru $d = 2$	7
2.19 Kernel intersectie: scufundare explicita	8
2.20 Kernel PQ	8
2.21 String kernel bazat pe biti de prezenta	8
2.22 Gradient descent, SGD si momentum	8
2.23 Graf computational si backpropagation	9
2.24 Retele neuronale si activari	9
2.25 Dead ReLU	9
2.26 Dropout	9
2.27 Xavier initialization	9
2.28 Convolutii si pooling	10
3 Sabloane rapide de rezolvare	11
3.1 Sablon: gradient pe nod $z = 2xy$	11
3.2 Sablon: strat convolutional	11
3.3 Sablon: kernel polinomial $d = 2$	11
3.4 Sablon: retea pentru o regiune geometrica	11

4 Rezolvari: Examen 2025 - Varianta 1	12
5 Rezolvari: 8 iunie 2022 - Varianta 1	14
6 Rezolvari: 8 iunie 2022 - Varianta 2	16
7 Rezolvari: 8 iunie 2022 - Varianta 3	17
8 Rezolvari: 8 iunie 2022 - Varianta 4	18
9 Rezolvari: 26 iunie 2023 - Variantele 3 si 4	19
9.1 Varianta 3 - grile 1–8	19
9.2 Varianta 3 - exercitiul cu kernel polinomial	19
9.3 Varianta 3 - problema cu multimile A, B, C	20
9.4 Varianta 3 - SVM hard-margin cu AND	20
9.5 Varianta 4 - grile lizibile	20
9.6 Varianta 4 - exercitiul cu kernel polinomial	21
10 Fisa finala de memorat	22
Observatii finale	22

Cum folosesti documentul

Invata documentul in ordinea aceasta:

1. Citeste teoria. Nu memora doar litera raspunsului; la examen se schimba enuntul, dar tiparul ramane acelasi.
2. Invata sabloanele de calcul: gradient, convolution/pooling, Kendall Tau, kernel polynomial, kernel intersectie, SVM primal-dual.
3. Rezolva grilele fara raspuns, apoi verifica explicatia.
4. La problemele cu figuri, ideea importanta este sa scrii inegalitatile dreptelor si sa le combini cu neuroni de tip prag/AND.

1 Tiparul examenului

Din modelele trimise se repeta urmatoarele teme:

- intrebari grila scurte: eroare de modelare/estimare/optimizare, no free lunch, Hughes, bias/variance, BatchNorm, Dropout, activari;
- calcule de gradient pe graf computational;
- calcule pentru straturi convolutionale si pooling;
- kerneluri: RBF, Hellinger, intersectie, PQ/Kendall, string kernels, kernel polinomial si scufundare explicita;
- SVM: hard margin, soft margin, variabile slack ξ , ponderi duale α , clasificare cu $\text{sign}(w^T \phi(x) + b)$;
- retele neuronale pentru regiuni geometrice si XOR;
- normalizare L1/L2 si interpretarea geometrica in $\mathbb{R}^3$.

2 Teorie dezvoltata pentru examen

2.1 Invatare automata: obiectiv si notatie

Avem exemple de antrenare

$$S = \{(x_i, y_i)\}_{i=1}^n,$$

unde x_i este input-ul si y_i este eticheta/valoarea tinta. Scopul este sa invatam o functie

$$f : X \rightarrow Y$$

care sa aiba performanta buna pe date noi, nu doar pe datele de antrenare.

Ideea de baza: alegem un spatiu de ipoteze H , o functie de pierdere L si o metoda de optimizare. Modelul final este o ipoteza $h \in H$ care minimizeaza aproximativ pierderea.

2.2 Tipuri de invatare

Tip	Ce inseamna
Supervizata	Avem perechi etichetate (x_i, y_i) . Include clasificare si regresie.
Nesupervizata	Avem doar x_i , fara etichete. Exemple: clustering, reducere dimensionalitate.
Semi-supervizata	Avem putine exemple etichetate si multe neetichetate.
Ranforsata	Agentul invata din recompense. Datele sunt secventiale, actiunile influenteaza viitorul.
Activa	Modelul alege ce exemple sa fie etichetate.
Transfer	Folosim cunostinte dintr-o problema/domeniu pentru alta problema.

2.3 Train, validation, test

- **Train:** invata parametrii modelului, de exemplu w, b .
- **Validation:** alege hiperparametrii, de exemplu k, C, λ , learning rate, arhitectura.
- **Test:** evalueaza final modelul ales. Nu se foloseste pentru alegerea modelului.

Capcana. Daca alegi modelul dupa scorul de test, faci *data leakage*; scorul final devine prea optimist.

2.4 Erori: modelare, estimare, optimizare

Eroarea unui sistem de invatare se descompune conceptual in:

1. **Eroare de modelare:** spatiul de ipoteze este nepotrivit/prea restrictiv. Exemplu: incerci sa rezolvi XOR cu un singur clasificator liniar.
2. **Eroare de estimare:** ai prea putine date pentru a estima bine parametrii.
3. **Eroare de optimizare:** algoritmul nu ajunge la minimul dorit al functiei de pierdere.

Grila tipica: “Cum se descompune eroarea?” Raspuns: **modelare, estimare si optimizare.**

2.5 Eroare empirica si eroare de generalizare

Eroarea de generalizare este eroarea asteptata pe date nevazute. Nu o cunoastem exact, deci o aproximam prin eroarea empirica pe un set de test/validare.

$$R(h) = \mathbb{E}_{(x,y) \sim P}[L(h(x), y)], \quad \hat{R}(h) = \frac{1}{n} \sum_{i=1}^n L(h(x_i), y_i).$$

Cand $n \rightarrow \infty$ si datele sunt i.i.d., eroarea empirica aproximeaza eroarea de generalizare.

2.6 Bias, variance, underfitting, overfitting

Concept	Simptom	Solutie tipica
Bias mare / underfitting	model prea simplu, train prost si test prost	model mai complex, feature-uri mai bune, strat nou
Variance mare / overfitting	train bun, test prost	regularizare, dropout, mai multe date, model mai simplu

2.7 No free lunch si fenomenul Hughes

No free lunch: nu exista un singur model optim pentru toate problemele. Un model bun pe o distributie poate fi slab pe alta.

Fenomenul Hughes: cand numarul de trasaturi creste mult fata de numarul de exemple, performanta poate scadea. Intuitiv, spatiul devine rar, iar estimarea devine instabila. In grile apare ca “prea multe trasaturi” sau, echivalent, “prea putine exemple pentru numarul de trasaturi”.

2.8 Metrice de evaluare

Pentru clasificare binara:

	Prezis pozitiv	Prezis negativ
Real pozitiv	TP	FN
Real negativ	FP	TN

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$
$$F_1 = \frac{2PR}{P + R}, \quad F_\beta = (1 + \beta^2) \frac{PR}{\beta^2 P + R}.$$

- $\beta = 1$: precision si recall sunt echilibrate.
- $\beta > 1$: se favorizeaza recall.
- $\beta < 1$: se favorizeaza precision.
- $\beta = 0$: $F_0 = P$.

False positive rate:

$$FPR = \frac{FP}{FP + TN}.$$

2.9 Kendall Tau

Kendall Tau compara doua ordonari. Pentru fiecare pereche de exemple:

- concordanta: ordinea reala si ordinea prezisa coincid;
- discordanta: ordinea reala si ordinea prezisa sunt inverse.

Pentru n exemple sunt $\binom{n}{2}$ perechi:

$$\tau = \frac{P - Q}{\binom{n}{2}},$$

unde P este numarul de perechi concordante si Q numarul de perechi discordante.

Exemplu de examen. Etichete reale $[0.1, 0.2, 0.3, 0.4, 0.5]$, predictii $[0.4, 0.2, 0.6, 1.0, 0.8]$. Ordinea reala este $1 < 2 < 3 < 4 < 5$. Perechile discordante sunt $(1, 2)$ si $(4, 5)$, deci $Q = 2$, $P = 8$ si

$$\tau = \frac{8 - 2}{10} = 0.6.$$

2.10 Naive Bayes si Laplace smoothing

Regula Bayes:

$$P(c | X) = \frac{P(X | c)P(c)}{P(X)}.$$

La clasificare, $P(X)$ este acelasi pentru toate clasele, deci alegem:

$$\hat{c} = \arg \max_c P(c) \prod_{j=1}^d P(x_j | c).$$

In practica folosim logaritmi:

$$\hat{c} = \arg \max_c \left[\log P(c) + \sum_{j=1}^d \log P(x_j | c) \right].$$

Presupunerea “naiva”: atributele sunt independente conditionat de clasa.

Laplace smoothing evita probabilitatile zero:

$$P(x = v | c) = \frac{N_{c,v} + \alpha}{N_c + \alpha K},$$

unde K este numarul de valori posibile pentru atribut. Daca $\alpha = 1$, este smoothing Laplace clasic.

2.11 k-NN si distante

Algoritmul k-NN:

1. pentru exemplul de test x , calculeaza distantele fata de toate exemplele de train;
2. alege cei mai apropiati k vecini;

3. pentru clasificare: vot majoritar; pentru regresie: media valorilor.

$$L_1(x, y) = \sum_i |x_i - y_i|, \quad L_2(x, y) = \sqrt{\sum_i (x_i - y_i)^2}, \quad L_p(x, y) = \left(\sum_i |x_i - y_i|^p \right)^{1/p}.$$

- k mic: frontiera este mai neregulata, variance mai mare.
- k mare: frontiera este mai neteda, bias mai mare.
- Normalizarea este importanta: o trasatura cu valori mari poate domina distanta.

2.12 Standardizare si normalizare

Standardizare pe dimensiuni:

$$x_{scaled} = \frac{x - \mu}{\sigma}.$$

Media μ si deviatia standard σ se calculeaza pe train si se aplica pe validation/test.

Normalizare L1/L2 pe exemplu:

$$x_{L1} = \frac{x}{\|x\|_1}, \quad x_{L2} = \frac{x}{\|x\|_2}.$$

In $\mathbb{R}^3$, normalizarea L2 proiecteaza punctele nenule pe sfera unitate:

$$S^2 = \{x \in \mathbb{R}^3 : \|x\|_2 = 1\}.$$

2.13 Batch normalization

Pentru un mini-batch $B = \{x_1, \dots, x_m\}$, pe fiecare dimensiune se calculeaza:

$$\mu_B = \frac{1}{m} \sum_i x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_i (x_i - \mu_B)^2,$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \quad y_i = \gamma \hat{x}_i + \beta.$$

Daca batch-ul are un singur exemplu, atunci $\mu_B = x_1$ si $\sigma_B^2 = 0$, deci $\hat{x}_1 = 0$. Fara parametrii γ, β , iesirea normalizata devine vectorul zero.

2.14 Clasificatori liniari, SVM si Softmax

Un clasificator liniar produce scoruri:

$$s = Wx + b.$$

Pentru SVM multiclass, pierderea pe exemplul i este:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + \Delta).$$

SVM vrea ca scorul clasei corecte sa fie cu o marja peste celelalte.

Softmax transforma scorurile in probabilitati:

$$P(y = j \mid x) = \frac{e^{s_j}}{\sum_k e^{s_k}}, \quad L_i = -\log P(y_i \mid x_i).$$

2.15 SVM hard-margin, soft-margin si variabila ξ

Hard-margin:

$$y_i(w^T x_i + b) \geq 1.$$

Soft-margin introduce variabile slack:

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Interpretare:

- $\xi_i = 0$: punctul respecta marginea;
- $0 < \xi_i < 1$: punctul este in margine, dar corect clasificat;
- $\xi_i \geq 1$: punctul poate fi gresit clasificat.

Parametrul C controleaza penalizarea erorilor: C mare forteaza train mai bun, dar poate produce overfitting; C mic accepta greseli, dar poate produce underfitting.

2.16 Kernel trick

Un kernel este un produs scalar implicit:

$$k(x, z) = \langle \phi(x), \phi(z) \rangle.$$

Nu trebuie sa calculam explicit coordonatele $\phi(x)$ daca algoritmul foloseste doar produse scalare.

Kernel	Formula	Cand apare
Linier	$k(x, z) = x^T z$	date aproape linier separabile
Polinomial	$k(x, z) = (x^T z + c)^d$	interactiuni polinomiale
RBF	$k(x, z) = \exp(-\gamma \ x - z\ _2^2)$	date neliniare; transformata distantă L2
Intersectie	$k(x, z) = \sum_i \min(x_i, z_i)$	histograme/frecvente
Hellinger	$k(x, z) = \sum_i \sqrt{x_i z_i} = \langle \sqrt{x}, \sqrt{z} \rangle$	histograme normalizate
PQ	$k_{PQ}(X, Y) = 2(P - Q)$	compararea ordonarii componentelor
String	numara p -grame comune	texte/siruri

2.17 Operatii valide cu kerneluri

Daca k_1, k_2 sunt kerneluri valide, atunci sunt kerneluri valide:

$$k_1 + k_2, \text{quad} k_1 \ (a > 0), \quad k_1 \cdot k_2, \quad f(x)f(z), \quad k_1(\psi(x), \psi(z)).$$

Capcana. Nu orice combinatie cu k_1, k_2, k_3 este kernel. Trebuie sa ramana simetrica in argumente si pozitiv semidefinita. O transformare aplicata numai lui x sau numai lui z nu garanteaza kernel valid.

2.18 Scufundarea kernelului polinomial pentru $d = 2$

Pentru $x = (x_1, x_2)$ si $z = (z_1, z_2)$:

$$k(x, z) = (x^T z + c)^2 = (x_1 z_1 + x_2 z_2 + c)^2.$$

O scufundare explicita este:

$$\phi_c(x) = (x_1^2, x_2^2, \sqrt{2}x_1x_2, \sqrt{2}cx_1, \sqrt{2}cx_2, c).$$

Atunci $k(x, z) = \langle \phi_c(x), \phi_c(z) \rangle$.

2.19 Kernel intersectie: scufundare explicita

Pentru histograme cu valori intregi intre 0 si M :

$$\phi(x) = (\mathbf{1}[x_i \geq t])_{i=1..d, t=1..M}.$$

Atunci:

$$\langle \phi(x), \phi(y) \rangle = \sum_i \min(x_i, y_i).$$

2.20 Kernel PQ

Pentru fiecare pereche $1 \leq i < j \leq n$:

- concordanta: $(x_i - x_j)(y_i - y_j) > 0$;
- discordanta: $(x_i - x_j)(y_i - y_j) < 0$.

Kernelul din curs este:

$$k_{PQ}(X, Y) = 2(P - Q).$$

Un mod de a-l vedea, fara egalitati, este:

$$\phi(X) = \sqrt{2}(\text{sign}(x_i - x_j))_{i < j}, \quad \langle \phi(X), \phi(Y) \rangle = 2(P - Q).$$

Daca apar egalitati si enuntul foloseste ≥ 0 pentru P , la examen numeri perechile exact dupa definitia din enunt.

2.21 String kernel bazat pe biti de prezenta

Pentru p -game, fiecare sir devine multimea p -gramelor unice. Kernelul cu biti de prezenta este numarul de p -game comune.

Exemplu: $s = \text{"ana are mere"}$, $t = \text{"ioana are banane"}$, cu 2-game si spatiile notate prin $_$:

$$S = \{an, na, a_, _a, ar, re, e_, _m, me, er\},$$

$$T = \{io, oa, an, na, a_, _a, ar, re, e_, _b, ba, ne\}.$$

Intersectia are 7 elemente:

$$\{an, na, a_, _a, ar, re, e_\}.$$

2.22 Gradient descent, SGD si momentum

Pentru minimizare:

$$W \leftarrow W - \eta \nabla_W L.$$

Gradientul indica directia de crestere maxima, deci pentru minimizare il scadem.

SGD foloseste un exemplu sau un mini-batch, nu tot setul de train. Cu momentum:

$$v_{t+1} = \mu v_t - \eta \nabla L(W_t), \quad W_{t+1} = W_t + v_{t+1}.$$

- $\mu = 0$: SGD standard.
- $\mu \approx 0.9$: viteza pastreaza directia anterioara si netezeste oscilatiile.
- $\mu = 1$: nu exista amortizare; viteza acumuleaza gradientii si algoritmul poate diverge.

Capcana. Daca ti se da doar pozitia curenta x_t la momentum, dar nu si viteza v_t , urmatorul pas nu se poate calcula.

2.23 Graf computational si backpropagation

Un graf computational descompune o functie in operatii simple. In forward calculezi valorile; in backward propagi gradientii cu regula lantului.

Daca $z = 2xy$ si primesti $\frac{\partial L}{\partial z} = g$, atunci:

$$\begin{aligned}\frac{\partial z}{\partial x} &= 2y, & \frac{\partial z}{\partial y} &= 2x, \\ \frac{\partial L}{\partial x} &= g \cdot 2y, & \frac{\partial L}{\partial y} &= g \cdot 2x.\end{aligned}$$

Exemplu. Pentru $x = -0.5$, $y = 2$, $g = -5$:

$$\frac{\partial L}{\partial x} = -5 \cdot 4 = -20, \quad \frac{\partial L}{\partial y} = -5 \cdot (-1) = 5.$$

2.24 Retele neuronale si activari

Un strat liniar singur are forma $Wx + b$. Mai multe straturi liniare fara activare neliniara raman tot o transformare liniara. De aceea, pentru date neliniar separabile ai nevoie de cel putin un strat ascuns cu activare neliniara.

Activare	Formula	Observatii
Sigmoid	$\sigma(x) = 1/(1 + e^{-x})$	valori in $(0, 1)$; satureaza
Tanh	$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	valori in $(-1, 1)$; medie mai buna
ReLU	$\max(0, x)$	simpla; poate produce dead ReLU
Leaky ReLU / PReLU	$\max(\alpha x, x)$	pastreaza gradient pe negativ
ELU	x daca $x \geq 0$, $\lambda(e^x - 1)$ daca $x < 0$	neteda pe zona negativa
Maxout	$\max_j(w_j^T x + b_j)$	poate invata functii convexe pe bucati

2.25 Dead ReLU

Dead ReLU apare cand intrarea in ReLU este mereu negativa:

$$z = w^T x + b < 0 \Rightarrow \text{ReLU}(z) = 0, \quad \text{ReLU}'(z) = 0.$$

Daca derivata este zero pentru toate exemplele, neuronul nu mai primeste gradient util.

2.26 Dropout

Dropout dezactiveaza aleator unele activari in timpul antrenarii. Este echivalent intuitiv cu adaugarea unui zgomot de tip "piper" / salt-and-pepper pe activari, pentru ca unele valori sunt puse la zero.

2.27 Xavier initialization

Initializarea Xavier alege varianta ponderilor astfel incat activatiile si gradientii sa nu explodeze si sa nu dispara prea repede. Este folosita mai ales pentru tanh/sigmoid. Nu corecteaza direct bias-ul conceptual al modelului; pentru bias mare ai nevoie de capacitate mai mare sau feature-uri mai bune.

2.28 Convolutii si pooling

Pentru un strat convolutional cu:

- F filtre;
- kernel $k_h \times k_w$;
- C_{in} canale de intrare;

numarul de parametri este:

$$F \cdot (k_h k_w C_{in} + 1),$$

unde +1 este bias-ul fiecarui filtru.

Dimensiunea spatiala de iesire:

$$H_{out} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1, \quad W_{out} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1.$$

La convolution, numarul de canale de iesire este numarul de filtre. La pooling, numarul de canale ramane acelasi.

3 Sabloane rapide de rezolvare

3.1 Sablon: gradient pe nod $z = 2xy$

1. Calculez derivatele locale: $\partial z/\partial x = 2y$, $\partial z/\partial y = 2x$.
2. Inmultesc cu gradientul primit de sus: $\partial L/\partial x = (\partial L/\partial z)(2y)$.
3. Atentie la semne.

3.2 Sablon: strat convolutional

1. Parametri: $F(k_h k_w C_{in} + 1)$.
2. Spatial: $\lfloor (H - K + 2P)/S \rfloor + 1$.
3. Canale output: F .

3.3 Sablon: kernel polinomial $d = 2$

Pentru c dat:

$$\phi_c(x_1, x_2) = (x_1^2, x_2^2, \sqrt{2}x_1x_2, \sqrt{2}cx_1, \sqrt{2}cx_2, c).$$

Daca ai ponderi duale semnate α_i , atunci:

$$w = \sum_i \alpha_i \phi(x_i), \quad \hat{y} = \text{sign}(w^T \phi(x_{test}) + b).$$

3.4 Sablon: retea pentru o regiune geometrica

Pentru o regiune definita ca intersectie de semiplane:

$$a_1x + b_1y + c_1 \geq 0, \quad \dots, \quad a_kx + b_ky + c_k \geq 0,$$

folosesti:

- strat ascuns cu k neuroni prag, cate unul pentru fiecare inegalitate;
- output de tip AND: $\mathbf{1}[h_1 + \dots + h_k \geq k - 0.5]$.

Pentru complementul unei regiuni, inversezi iesirea finala.

4 Rezolvari: Examen 2025 - Varianta 1

Grile 1–10

Nr.	Rasp.	Explicatie
1	D	Variabila ξ este slack-ul din SVM soft-margin si permite incalcarea marginii / ignorarea unor puncte neliniar separabile.
2	B	BatchNorm pe un singur exemplu: media este chiar exemplul, varianta este 0, deci valoarea normalizata devine 0.
3	A	$\frac{e^x - e^{-x}}{e^x + e^{-x}} = \tanh(x)$, iar $\max(0, \tanh(x)) = \text{ReLU}(\tanh(x))$.
4	B	Se numara 2-gramele comune cu biti de prezenta. Incluzand spatiile, intersectia are 7 elemente.
5	D	In forma exacta din grila, niciuna nu este garantat kernel valid. Suma/produsul sunt valide doar pentru kerneluri pe aceleasi argumente, cu simetrie si PSD.
6	B	RBF transforma distanta L2 intr-o similaritate: $\exp(-\gamma \ x - y\ _2^2)$.
7	D	La momentum $\mu = 1$ nu mai exista amortizare, deci algoritmul poate diverge/oscila.
8	A	Date neliniar separabile: e nevoie de cel putin un strat ascuns cu activare neliniara.
9	D	Cand $n \rightarrow \infty$, eroarea empirica estimeaza eroarea de generalizare.
10	C	Sunt 10 perechi; discordante: (1, 2) si (4, 5). Deci $\tau = (8 - 2)/10 = 0.6$.

11. Neuron ReLU si Maxout

Se da

$$S = \{([1, 1, 0], 1), ([0, 1, 0], 0), ([0, 1, 1], 1), ([1, 1, 1], 0)\},$$

$w = [0, -1, 0]$, $b = 0.5$, activare ReLU.

a) **Aplicarea neuronului.** Pentru orice exemplu, $x_2 = 1$, deci:

$$w^T x + b = 0 \cdot x_1 - 1 \cdot x_2 + 0 \cdot x_3 + 0.5 = -0.5.$$

$$\text{ReLU}(-0.5) = 0.$$

Deci neuronul da iesirea 0 pentru toate cele patru exemple.

b) **Problema la optimizare.** Apare **dead ReLU**. Toate preactivarile sunt negative, deci derivata ReLU este 0, iar gradientul nu modifica eficient ponderile. O valoare buna pentru bias este, de exemplu, $b = 1.5$:

$$w^T x + b = -1 + 1.5 = 0.5 > 0.$$

Acum neuronul intra in zona liniara a ReLU si gradientul poate trece.

c) **Maxout cu eroare 0.** Eticheta este 1 exact cand $x_1 \neq x_3$ si 0 cand $x_1 = x_3$. Putem folosi:

$$f(x) = \max(x_1 - x_3, x_3 - x_1) = |x_1 - x_3|.$$

Parametri:

$$w_1 = (1, 0, -1), \quad b_1 = 0, \quad w_2 = (-1, 0, 1), \quad b_2 = 0.$$

Pentru valori binare, $|x_1 - x_3|$ este exact XOR, deci prezice perfect etichetele.

12. Normalizare L2 in $\mathbb{R}^3$

a) **Obiect geometric.** Orice punct nenul $x \in \mathbb{R}^3$ devine

$$x' = \frac{x}{\|x\|_2}, \quad \|x'\|_2 = 1.$$

Deci punctele se proiecteaza pe **sfera unitate** centrata in origine.

b) **Separarea punctelor cu $x_1 > 0$.** Da. Folosim neuronul liniar:

$$f(x) = w^T x + b, \quad w = (1, 0, 0), \quad b = 0.$$

Atunci $f(x) = x_1$. Cu regula “pozitiv daca $f(x) > 0$ ”, separa punctele cu prima coordonata pozitiva de toate celelalte.

5 Rezolvari: 8 iunie 2022 - Varianta 1

Nr.	Rasp.	Rezolvare
1	A	Pentru $z = 2xy$, $\partial z/\partial x = 2y = 4$, $\partial z/\partial y = 2x = -1$. Cu $\partial L/\partial z = -5$: $\partial L/\partial x = -20$, $\partial L/\partial y = 5$.
2	D	RBF are scufundare Hilbert infinita, dar nu o scufundare finita simpla dintre variante. Formula din C este kernelul, nu scufundarea.
3	A	Eroarea se descompune in modelare, estimare si optimizare.
4	C	No free lunch: nu exista un singur model bun pe toate task-urile.
5	B	Hughes apare cand sunt prea multe trasaturi fata de numarul de exemple.
6	B	$30(5 \cdot 5 \cdot 10 + 1) = 30 \cdot 251 = 7530$.
7	C	Capacitatea neliniara vine din functiile de transfer/activare.
8	C	Pooling 2×2 , stride 4: $\lfloor (66 - 2)/4 \rfloor + 1 = 17$, deci $17 \times 17 \times 40$.

9. Kernel PQ

Pentru $x = (0, 4, 1, 2)$ si $y = (1, 3, 5, 1)$ avem 6 perechi.

Pereche	$x_i - x_j$	$y_i - y_j$	Tip
(1,2)	-4	-2	P
(1,3)	-1	-4	P
(1,4)	-2	0	P, daca enuntul foloseste ≥ 0
(2,3)	3	-2	Q
(2,4)	2	2	P
(3,4)	-1	4	Q

Deci $P = 4$, $Q = 2$ si:

$$k_{PQ}(x, y) = 2(P - Q) = 2(4 - 2) = 4.$$

O scufundare pentru cazul fara egalitati este:

$$\phi(x) = \sqrt{2}(\text{sign}(x_i - x_j))_{i < j}.$$

10. Activare $f(x) = \max(0, x)e^{-x+1}$ si XOR

Da, un singur neuron cu aceasta activare poate rezolva XOR daca folosim un prag pe iesire. Alegem:

$$z = x_1 + x_2.$$

Pentru XOR:

$$(0, 0) \Rightarrow z = 0, \quad (1, 0), (0, 1) \Rightarrow z = 1, \quad (1, 1) \Rightarrow z = 2.$$

Iesirile sunt:

$$f(0) = 0, \quad f(1) = 1, \quad f(2) = \frac{2}{e} \approx 0.736.$$

Cu prag 0.8, exemplele cu XOR=1 au iesire $1 > 0.8$, iar exemplele cu XOR=0 au iesiri 0 si $0.736 < 0.8$.

11. Retea pentru triunghiul A

Figura are A in interiorul triunghiului cu varfuri aproximative (1, 4), (5, 4), (3, 1) si B in exterior. Inegalitatile pentru A sunt:

$$y \leq 4, \quad 3x + 2y \geq 11, \quad -3x + 2y \geq -7.$$

Strat ascuns cu trei neuroni prag:

$$h_1 = \mathbf{1}[4 - y \geq 0], \quad h_2 = \mathbf{1}[3x + 2y - 11 \geq 0], \quad h_3 = \mathbf{1}[-3x + 2y + 7 \geq 0].$$

Output:

$$o = \mathbf{1}[h_1 + h_2 + h_3 \geq 2.5].$$

Atunci $o = 1$ pentru A si $o = 0$ pentru B. Daca eticheta ceruta pentru B este -1 , folosim $\hat{y} = 2o - 1$.

6 Rezolvări: 8 iunie 2022 - Varianta 2

Nr.	Rasp.	Rezolvare
1	B	Eroarea de modelare apare cand modelul/spatiul de ipoteze are capacitate slaba pentru realitate.
2	C	Teorema aproximarii universale: rețelele neuronale pot aproxima orice functie continua pe compact, cu ipotezele standard.
3	C	Pentru $z = 2xy$: $\partial L / \partial x = -20$, $\partial L / \partial y = 5$.
4	C	$10(5 \cdot 5 \cdot 30 + 1) = 10 \cdot 751 = 7510$.
5	D	Neliniaritatea este data de functiile de activare.
6	A	Pooling 4×4 , stride 2: $\lfloor (66 - 4) / 2 \rfloor + 1 = 32$, deci $32 \times 32 \times 40$.
7	A	Pentru Hellinger, scufundarea este $\phi(x) = \sqrt{x}$ pe componente.
8	A	Hughes: prea putine exemple raportat la numarul de trasaturi; varianta echivalenta cu "prea multe trasaturi".

9. Kernel intersectie

$$k(x, y) = \sum_i \min(x_i, y_i), \quad x = (0, 4, 1, 2), \quad y = (3, 2, 5, 3).$$

$$k(x, y) = \min(0, 3) + \min(4, 2) + \min(1, 5) + \min(2, 3) = 0 + 2 + 1 + 2 = 5.$$

Pentru frecventa maxima 5, definim:

$$\phi(x) = (\mathbf{1}[x_i \geq t])_{i=1..4, t=1..5}.$$

Pentru fiecare componenta, produsul scalar numara cate praguri t sunt depasite de ambele valori, adica $\min(x_i, y_i)$. Suma pe componente da kernelul.

10. XOR

Aceeasi rezolvare ca in varianta 1: alegem $z = x_1 + x_2$ si prag 0.8 pe $f(z) = \max(0, z)e^{-z+1}$. Se obtine separarea XOR.

11. Retea pentru dreptunghiul B

Figura arata B ca dreptunghiul $1 \leq x \leq 5$, $1 \leq y \leq 2$, iar A este exteriorul. Construim mai intai detectorul pentru B:

$$h_1 = \mathbf{1}[x - 1 \geq 0], \quad h_2 = \mathbf{1}[5 - x \geq 0], \quad h_3 = \mathbf{1}[y - 1 \geq 0], \quad h_4 = \mathbf{1}[2 - y \geq 0].$$

$$b_B = \mathbf{1}[h_1 + h_2 + h_3 + h_4 \geq 3.5].$$

Daca dorim A cu eticheta 1 si B cu eticheta -1 , iesirea poate fi:

$$\hat{y} = 1 - 2b_B.$$

7 Rezolvari: 8 iunie 2022 - Varianta 3

Nr.	Rasp.	Rezolvare
1	B	Eroarea se descompune in modelare, estimare si optimizare.
2	C	Hughes apare la prea multe trasaturi.
3	D	$20(3 \cdot 3 \cdot 40 + 1) = 20 \cdot 361 = 7220$.
4	A	Pentru RBF nu exista o scufundare finita simpla in variante; formula RBF este kernelul, nu ϕ .
5	B	Capacitatea neliniara vine din functiile de transfer/activare.
6	C	Aici $\partial L / \partial z = 5$. Pentru $z = 2xy$: $5 \cdot 4 = 20$ si $5 \cdot (-1) = -5$.
7	C	Convolutie 3×3 , stride 2 pe 65: $\lfloor (65-3)/2 \rfloor + 1 = 32$; 40 filtre $\Rightarrow 32 \times 32 \times 40$.
8	D	No free lunch: nu exista un singur model bun pe toate task-urile.

9. Kernel PQ

Pentru $x = (5, 2, 1, 0)$ si $y = (1, 3, 5, 1)$:

Pereche	$x_i - x_j$	$y_i - y_j$	Tip
(1,2)	3	-2	Q
(1,3)	4	-4	Q
(1,4)	5	0	P daca se foloseste ≥ 0
(2,3)	1	-2	Q
(2,4)	2	2	P
(3,4)	1	4	P

Cu conventia din enunt ≥ 0 , $P = 3$, $Q = 3$, deci

$$k_{PQ} = 2(P - Q) = 0.$$

10. XOR

Da, folosind $z = x_1 + x_2$ si prag 0.8 pe activarea data.

11. Retea pentru triunghiul A

Pentru triunghiul cu varfuri aproximative $(1, 1)$, $(5, 1)$, $(3, 4)$:

$$y \geq 1, \quad y \leq 1.5x - 0.5, \quad y \leq -1.5x + 8.5.$$

Neuroni ascunsi:

$$h_1 = \mathbf{1}[y - 1 \geq 0], \quad h_2 = \mathbf{1}[1.5x - 0.5 - y \geq 0], \quad h_3 = \mathbf{1}[-1.5x + 8.5 - y \geq 0].$$

Output:

$$o = \mathbf{1}[h_1 + h_2 + h_3 \geq 2.5].$$

Daca A are eticheta 1 si B -1, folosim $\hat{y} = 2o - 1$.

8 Rezolvări: 8 iunie 2022 - Varianta 4

Nr.	Rasp.	Rezolvare
1	B	Hellinger are scufundarea $\phi(x) = \sqrt{x}$ pe componente.
2	A	Capacitatea de modelare neliniara este data de functiile de activare.
3	A	Convolutie 3×3 , stride 2 pe 65: spatial 32×32 , iar 20 filtre dau 20 canale.
4	D	Teorema aproximarii universale: retelele neuronale pot aproxima orice functie continua pe compact.
5	A	Eroarea de modelare apare prin alegerea unui spatiu de ipoteze prea restrans.
6	C	$40(3 \cdot 3 \cdot 20 + 1) = 40 \cdot 181 = 7240$.
7	D	Hughes apare cand avem prea multe trasaturi.
8	B	Pentru $z = 2xy$, $\partial L / \partial z = -5$: $\partial L / \partial x = -20$, $\partial L / \partial y = 5$.

9. Kernel intersectie

$$x = (4, 0, 3, 2), \quad y = (3, 2, 5, 4).$$

$$k(x, y) = \min(4, 3) + \min(0, 2) + \min(3, 5) + \min(2, 4) = 3 + 0 + 3 + 2 = 8.$$

Scufundarea este aceeași ca la varianta 2:

$$\phi(x) = (\mathbf{1}[x_i \geq t])_{i=1..4, t=1..5}.$$

10. XOR

Se rezolva cu același neuron neliniar non-monoton: $z = x_1 + x_2$, iesiri $0, 1, 2/e$, prag 0.8 .

11. Retea pentru dreptunghiul B

B este dreptunghiul $2 \leq x \leq 4$, $1 \leq y \leq 4$, iar A este exteriorul. Detector B:

$$h_1 = \mathbf{1}[x - 2 \geq 0], \quad h_2 = \mathbf{1}[4 - x \geq 0], \quad h_3 = \mathbf{1}[y - 1 \geq 0], \quad h_4 = \mathbf{1}[4 - y \geq 0].$$

$$b_B = \mathbf{1}[h_1 + h_2 + h_3 + h_4 \geq 3.5].$$

Pentru A cu eticheta 1 și B cu eticheta -1 :

$$\hat{y} = 1 - 2b_B.$$

9 Rezolvari: 26 iunie 2023 - Variantele 3 si 4

Observatie. Pozele din 2023 sunt mai neclare, mai ales la exercitiile cu figuri. Mai jos sunt rezolvate toate cerintele lizibile; pentru figurile geometrice am scris sablonul complet de rezolvare si o configurare compatibila cu frontierele vizibile.

9.1 Varianta 3 - grile 1–8

Nr.	Rasp.	Rezolvare
1	B	Dropout pune aleator activari pe zero; este echivalent cu zgomot de tip piper/salt-and-pepper.
2	D	Cu momentum nu ajunge sa stim ca $x = -3$; trebuie si viteza v_t . Deci urmatoarea valoare nu se poate calcula.
3	D	Rata de fals pozitiv este $FP/(FP + TN)$.
4	C	Perceptronul Rosenblatt foloseste regula perceptronului, nu actualizare prin gradient al unei functii diferentiabile ca Widrow-Hoff/rețelele.
5	A	Bias mare inseamna model prea simplu; adaugarea unui strat creste capacitatea.
6	B	Eroarea de generalizare se aproximeaza practic prin eroarea empirica pe date de validare/test.
7	C	$f(x) = x$ pentru $x \geq 0$ si $\lambda(e^x - 1)$ pentru $x < 0$ este ELU.
8	A	Pentru $\beta = 0$, $F_0 = P$ din formula F_β .

9.2 Varianta 3 - exercitiul cu kernel polinomial

Date:

$$S = \{((1, -2), -1), ((1, 3), -1), ((3, -1), 1), ((1, 2), 1)\}, \quad x_t = (1, -3).$$

Kernel polinomial $d = 2$, $c = 4$:

$$k(x, z) = (x^T z + 4)^2.$$

a) Scufundarea.

$$\phi_4(x_1, x_2) = (x_1^2, x_2^2, \sqrt{2}x_1x_2, 2\sqrt{2}x_1, 2\sqrt{2}x_2, 4).$$

b) Aplicare pe test.

$$\phi_4(1, -3) = (1, 9, -3\sqrt{2}, 2\sqrt{2}, -6\sqrt{2}, 4).$$

c) Ponderi primale. Ponderile duale semnate din enunt sunt:

$$\alpha_1 = -0.5, \quad \alpha_2 = 0.5, \quad \alpha_3 = -1, \quad \alpha_4 = -2.$$

$$w = \sum_i \alpha_i \phi(x_i) = \left(-11, -\frac{13}{2}, \frac{3\sqrt{2}}{2}, -10\sqrt{2}, -\sqrt{2}, -12 \right).$$

d) Clasificarea testului. Cu $b = -2$:

$$w^T \phi(1, -3) + b = -\frac{313}{2} < 0.$$

Deci eticheta prezisa este:

$$\hat{y} = -1.$$

9.3 Varianta 3 - problema cu multimile A, B, C

Figura arata regiuni plane separate prin drepte orizontale si diagonala $y = x$. Procedura corecta la examen este:

1. Scrii fiecare frontiera ca inegalitate: de exemplu $y - x \geq 0$, $y - 4 \geq 0$, $3 - y \geq 0$ etc.
2. Faci cate un neuron prag pentru fiecare inegalitate.
3. Pentru fiecare clasa, faci un neuron output care realizeaza AND-ul inegalitatilor ce definesc regiunea.
4. Pentru un punct P, Q, R , calculezi valorile neuronilor ascunsi si apoi neuronul de clasa activ.

Un exemplu de arhitectura pentru trei regiuni este:

$$h_1 = \mathbf{1}[y - x \geq 0], \quad h_2 = \mathbf{1}[y - 4 \geq 0], \quad h_3 = \mathbf{1}[3 - y \geq 0], \quad h_4 = \mathbf{1}[x - y \geq 0].$$

Apoi se pot defini iesiri de tip:

$$o_C = \mathbf{1}[h_1 + h_2 \geq 1.5], \quad o_B = \mathbf{1}[h_3 + h_4 \geq 1.5], \quad o_A = \mathbf{1}[h_4 + (1 - h_3) \geq 1.5].$$

La redactare, important este sa justifici ca fiecare iesire corespunde intersectiei de semiplane din figura.

9.4 Varianta 3 - SVM hard-margin cu AND

Enuntul spune ca pentru functia logica AND s-au obtinut:

$$w = (2, 2), \quad b = -3.$$

Hiperplanul este:

$$2x_1 + 2x_2 - 3 = 0 \quad \Leftrightarrow \quad x_1 + x_2 = 1.5.$$

Se adauga exemplul $(1, 2)$ cu eticheta 1.

$$w^T x + b = 2 \cdot 1 + 2 \cdot 2 - 3 = 3 > 0.$$

Mai mult, pentru eticheta 1, constrangerea hard-margin este satisfacuta:

$$y(w^T x + b) = 3 \geq 1.$$

Deci punctul nu incalca marginea si nu forteaza schimbarea hiperplanului. Pozitia hiperplanului ramane aceeaasi.

9.5 Varianta 4 - grile lizibile

Nr.	Rasp.	Rezolvare
1	B	Daca intrebarea este despre corectarea variantei/varianței unei rețele cu 2 straturi, reduci capacitatea: elimini un strat sau regularizezi. Din variante, “eliminand un strat”.
2	D	Eroarea de generalizare se aproximeaza prin eroarea empirica.
3	C	Rata de fals pozitiv este $FP/(FP + TN)$.
4	D	Cu momentum, fara viteza curenta, urmatoarea pozitie nu se poate calcula.
5	C	Pentru $\beta = 0$, $F_0 = P$.
6	A	Modelul care nu este actualizat prin gradient in sensul clasic diferentiabil este perceptronul Rosenblatt.
7	A	Dropout este echivalent cu zgomot de tip piper pe activari.
8	B	Formula cu x pentru $x \geq 0$ si $\lambda(e^x - 1)$ pentru $x < 0$ este ELU.

9.6 Varianta 4 - exercitiul cu kernel polinomial

Din poza se citesc datele aproximativ ca:

$$S = \{((1, -2), 1), ((-2, 2), 1), ((3, -2), -1), ((1, -1), 1)\}, \quad x_t = (1, -2),$$

cu $d = 2$, $c = 5$ si ponderi duale semnate

$$\alpha_1 = -0.5, \quad \alpha_2 = 2, \quad \alpha_3 = -0.5, \quad \alpha_4 = 1.$$

a) Scufundarea.

$$\phi_5(x_1, x_2) = (x_1^2, x_2^2, \sqrt{2}x_1x_2, \sqrt{10}x_1, \sqrt{10}x_2, 5).$$

b) Test.

$$\phi_5(1, -2) = (1, 4, -2\sqrt{2}, \sqrt{10}, -2\sqrt{10}, 5).$$

c) Ponderi primale.

$$w = \sum_i \alpha_i \phi(x_i) = (4, 5, -5\sqrt{2}, -5\sqrt{10}, 5\sqrt{10}, 10).$$

d) Clasificare. Cu $b = 3$:

$$w^T \phi(1, -2) + 3 = -53 < 0,$$

deci:

$$\hat{y} = -1.$$

10 Fisa finala de memorat

Evaluare

- $Precision = TP/(TP + FP)$.
- $Recall = TP/(TP + FN)$.
- $FPR = FP/(FP + TN)$.
- $F_0 = P$.
- Kendall: $\tau = (P - Q)/\binom{n}{2}$.

Erori

- modelare: ipoteze nepotrivite;
- estimare: date putine;
- optimizare: algoritmul nu ajunge la optim;
- bias mare: underfitting;
- variance mare: overfitting.

SVM

- hiperplan: $w^T x + b = 0$;
- soft-margin: ξ_i ;
- C mare: risc overfitting;
- C mic: risc underfitting.

Kernel

- RBF: $\exp(-\gamma \|x - y\|^2)$;
- Hellinger: $\phi(x) = \sqrt{x}$;

Observatii finale

Pentru exercitiile cu figuri, profesorul nu verifica daca ai desenat exact ca in poza, ci daca ai inteles mecanismul: fiecare dreapta devine o inegalitate, fiecare inegalitate devine un neuron, iar intersectiile de semiplane se fac cu AND. Pentru SVM/kernel, cheia este sa nu sari pasul de scufundare $\phi(x)$: calculezi intai ϕ , apoi w , apoi semnul scorului.

- intersectie: praguri binare;
- polinomial $d = 2$: formula pentru ϕ_c ;
- PQ: $2(P - Q)$.

Optimizare

- GD: $W \leftarrow W - \eta \nabla L$;
- momentum: trebuie viteza v_t ;
- $\mu = 0$: SGD standard;
- $\mu = 1$: instabil/divergent.

Retele

- neliniar separabil: strat ascuns + activare neliniara;
- ReLU: $\max(0, x)$;
- ELU: $x / \lambda(e^x - 1)$;
- Maxout: $\max_j(w_j^T x + b_j)$;
- dead ReLU: $z < 0$ mereu, gradient zero;
- Dropout: zgomet de tip piper.

CNN

- parametri conv: $F(k_h k_w C_{in} + 1)$;
- spatial: $\lfloor (H - K + 2P)/S \rfloor + 1$;
- pooling pastreaza canalele.